31911번 - ChatGPT 만들기 성공 서브태스크

☆

골드 III

시간 제한	메모리 제한	제출	정답	맞힌 사람	정답 비율
1 초	1024 MB	481	135	106	27.749%

문제

GIST AI대학원에 재학 중인 지원이는 원칙적으로는 집에서 가정용 ChatGPT 정도는 쉽게 만들 수 있어야 한다. 하지만 지원이는 귀찮기 때문에 딥 러닝을 사용한 언어 모델 대신에 기본 NLP 기술인 n-gram 모델을 약간 수정하여 사용할 것이다.

지원이의 언어 모델은 문자 하나가 주어지면 훈련 코퍼스를 참조하여 다음 문자를 예측해 낸다. 훈련 코퍼스는 문자열 여러 개로 이루어져 있다. 어떤 문자 c가 주어지면, 지원이의 언어 모델은 훈련 코퍼스에 있는 모든 문자 c를 검색한 다음, 훈련 코퍼스에서 c 바로 다음 위치에 가장 많이 나오는 문자 c'를 찾아서 c 다음 문자가 c'일 것이라고 예측한다. $c = c'$일 수도 있음에 주의하라. 만약 그런 문자가 여러 개 있다면, 아스키 코드가 가장 작은 것을 선택한다. 만약 훈련 코퍼스에 문자 c가 존재하지 않는다면, 언어 모델이 다음 문자를 예측할 수 없어 오류가 발생한다.

훈련 코퍼스는 문장의 시작을 나타내는 문자 `[` 와 문장의 끝을 나타내는 문자 `]` , 알파벳 소문자 `a` - `z` , 그리고 띄어쓰기를 대체하는 문자 `-` 로만 구성되어 있다. 훈련 코퍼스 내의 모든 문장은 `[` 로 시작하고 `]` 로 끝나며 길이가 3 이상이다. 문자 `[` 는 반드시 문장의 시작에만 등장하고, 문자 `]` 는 반드시 문장의 끝에만 등장한다.

언어 모델을 사용하여 문장을 생성하는 방법은 다음과 같다. 먼저 언어 모델에 문장의 시작을 나타내는 문자 `[` 을 입력한다. 그 다음 언어 모델이 다음 문자 c_1을 예측하면, 생성하고 있는 문장의 끝에 예측한 문자를 추가한다. 그 다음 문자 c_1을 다시 언어 모델에 입력해 다음 문자 c_2를 예측한다. 이를 반복한다. 만약 반복 과정에서 문장의 끝을 나타내는 문자 `]` 가 등장하면 반복을 끝내고 예측을 종료한다. 그렇지 않다면, 다음 문자를 예측하는 과정은 무한히 반복된다. 훈련 코퍼스가 공집합이 아닌 한, 이 과정에서 언어 모델이 다음 문자를 예측할 수 없는 오류가 발생하지 않음을 증명할 수 있다.

훈련 코퍼스가 주어지면, 지원이와 함께 이 모델이 생성하는 문자열의 부분 문자열을 추측해 보자.

입력

첫째 줄에 세 정수 N, K, M이 공백으로 구분되어 주어진다. 이는 훈련 코퍼스가 총 N개의 문장으로 이루어져 있고, 프로그램은 이 훈련 코퍼스로 훈련한 언어 모델이 생성한 문자열의 K번째 문자부터 $K + M - 1$번째 문자까지를 출력해야 한다는 것을 의미한다. ($1 \le N \le 100\,000$, $1 \le K \le 10^{18}$, $1 \le M \le 1\,000$)

둘째 줄부터 N개의 줄에 걸쳐 훈련 코퍼스에 들어 있는 문장들이 문자열의 형태로 한 줄에 하나씩 주어진다. 각 줄은 `[` 로 시작하고 `]` 로 끝나며 길이가 3 이상이다. 문자 `[` 는 반드시 각 줄의 시작에만 등장하고, 문자 `]` 는 반드시 각 줄의 끝에만 등장한다.

훈련 코퍼스에 존재하는 모든 문자의 길이의 합은 $300\,000$을 넘지 않는다.

출력

입력된 훈련 코퍼스로 훈련한 언어 모델이 생성한 문자열의 K번째 문자부터 $K + M - 1$번째 문자까지를 출력한다. i번째 문자를 출력할 때, 만약 언어 모델이 생성한 문자열의 길이가 짧아 i번째 문자가 존재하지 않는다면, 문자 `.` 를 대신 출력한다.

서브태스크

번호	배점	제한
1	25	$K \le 100\,000$
2	75	추가 제약 조건이 없다.

예제 입력 1 복사

```
3 1 15
[i-love-you]
[my-name-is-james]
[gist-algorithm-masters]
```

예제 출력 1 복사

```
[gis].........
```

언어 모델이 문장을 생성하는 방식은 다음과 같다.

언어 모델에 문장의 시작을 나타내는 문자 `[` 를 입력한다. 훈련 코퍼스에서 문자 `[` 바로 다음 위치에 등장하는 문자는 `g` 1개, `i` 1개, `m` 1개이다. 따라서 `g`, `i`, `m` 이 가장 많이 등장하므로 이들 중 아스키 코드가 가장 작은 `g` 를 다음 문자로 선택한다.

언어 모델에 `g` 를 입력한다. 훈련 코퍼스에서 `g` 바로 다음 위치에 등장하는 문자는 `i` 1개, `o` 1개이다. 따라서 `i`, `o` 가 가장 많이 등장하므로 이들 중 아스키 코드가 가장 작은 `i` 를 다음 문자로 선택한다.

언어 모델에 `i` 를 입력한다. 훈련 코퍼스에서 `i` 바로 다음 위치에 등장하는 문자는 `-` 1개, `s` 2개, `t` 1개이다. 따라서 `s` 가 가장 많이 등장하므로 `s` 를 다음 문자로 선택한다.

언어 모델에 `s` 를 입력한다. 훈련 코퍼스에서 `s` 바로 다음 위치에 등장하는 문자는 `-` 1개, `]` 2개, `t` 2개이다. 따라서 `]`, `t` 가 가장 많이 등장하므로 이들 중 아스키 코드가 가장 작은 `]` 를 다음 문자로 선택한다.

언어 모델이 문장의 끝을 나타내는 문자 `]` 를 선택했으므로 더 이상 예측을 진행하지 않는다. 따라서 그 이후 자리를 모두 `.` 로 채운다.

예제 입력 2 복사

```
4 1 15
[i-love-you]
[my-name-is-james]
[gist-algorithm-masters]
[dresscode]
```

예제 출력 2 복사

```
[de-ame-ame-ame
```

노트

문자 `-` 의 아스키 코드는 `45`, `[` 의 아스키 코드는 `91`, `]` 의 아스키 코드는 `93`, `a` 의 아스키 코드는 `97` 이다.

출처

University (/category/5) > 광주과학기술원 (/category/434) > 2024 GIST 알고리즘 마스터즈 (/category/detail/4225) E번

- 문제를 만든 사람: invrtd_h (/user/invrtd_h)
- 문제를 검수한 사람: 99asdfg (/user/99asdfg), dohoon (/user/dohoon), gs22123 (/user/gs22123), leo020630 (/user/leo020630), lys9546 (/user/lys9546), petamingks (/user/petamingks)

알고리즘 분류

- 구현 (/problem/tag/102)
- 자료 구조 (/problem/tag/175)
- 그래프 이론 (/problem/tag/7)

- 문자열 (/problem/tag/158)
- 집합과 맵 (/problem/tag/225)
- 해시를 사용한 집합과 맵 (/problem/tag/136)

채점 및 기타 정보

- 예제는 채점하지 않는다.

메모